

Transcrire les manuscrits médiévaux français

Volet 1 — Reconnaissance automatique d'écriture manuscrite (HTR)

D'un modèle générique inutilisable à **13,46 % d'erreur caractère** sur un test scellé —
une division par **5,7** du taux d'erreur, en pipeline complet et reproductible.

Équipe : _____ · _____ · _____ | Corpus : CATMuS Medieval (sous-ensemble français)

CONTEXTE & OBJECTIFS

Une image n'est pas un texte

La BnF et Gallica ont numérisé des centaines de milliers de pages de manuscrits. Mais pour une machine, un scan reste une grille de pixels : impossible de chercher, d'indexer ou d'analyser le contenu. Transcrire à la main, en paléographie, coûte de l'ordre de 50 €/h — hors d'échelle pour des corpus entiers.

NOTRE OBJECTIF

Construire une chaîne complète qui transforme une **page brute** de manuscrit médiéval français en **transcription fidèle et localisée**, directement exploitable en aval.

DEUX VOLETS, EN SÉQUENCE

Volet 1 (CV/HTR) — image → texte + structure spatiale.

Volet 2 (NLP) — normalisation, entités, graphe de connaissances.

Le pont entre les deux : un data contract JSON validé, que nous avons conçu et livré.

DONNÉES

Le corpus — CATMuS Medieval, sous-ensemble français

CATMuS Medieval est un corpus de référence sous licence ouverte, images majoritairement issues de la BnF/Gallica, lignes déjà transcrites par des spécialistes. Nous avons restreint au **français** : cohérence linguistique pour le décodeur, et téléchargement ciblé (~20 Go au lieu de ~96 Go toutes langues).

49 201

lignes d'entraînement

2 712

validation

4 135

test scellé

BIAIS DOCUMENTÉS (SECTION ÉTHIQUE)

Temporel : pic 13^e–15^e s., peu de 11^e–12^e. Paléographique : écriture *Textualis* dominante. Le modèle est donc plus fiable sur ces profils que sur des écritures rares.

CONVENTION DE TRANSCRIPTION

Semi-diplomatique : on conserve les abréviations (ñ, 7) et on normalise en Unicode NFC. La résolution des abréviations est laissée au Volet 2.

Du brut au prêt-à-entraîner — module `src/data.py`, testé

SÉLECTION & DÉCODAGE

Filtrage des fichiers L-Fre* (français isolé) ; décodage des images de lignes en PIL RGB.

NORMALISATION DU TEXTE

Unicode **NFC** + suppression des espaces de bord (`nettoyer_texte`). Les signes médiévaux sont **préservés** — choix éditorial assumé.

FILTRAGE QUALITÉ


Retrait des lignes vides ou trop courtes (`nettoyer_corpus`), avec un rapport avant/après par split.

PARTITION & SCHELLEMENT

Splits **officiels** CATMuS (aucun re-découpage, aucune fuite). SHA-256 du train + seed 42 fixé partout.

```
train SHA-256 : 11a7b277d73e53c540aba23fdd2f7533ea7068f790e16e4699a5d69fcc87c26c
seed          : 42      ·   tests pytest sur la normalisation : 4 / 4 OK
```

Du pixel à la ligne de texte



PRÉTRAITEMENT (PARAMÉTRABLE, TESTÉ)

Correction d'inclinaison par maximisation de variance du profil ; CLAHE pour le contraste local ; binarisation de Sauvola, adaptée aux fonds anciens non uniformes où un seuil global échoue.

SEGMENTATION & STRUCTURE DE PAGE

Régions texte/marge avec ordre de lecture, puis lignes (Kraken BLLA — baselines et polygones ; fallback par projection). Export en **PAGE XML**, compatible eScriptorium/Kraken.

Point que nous assumerons en diapo 10 : la qualité de la segmentation pilote directement le CER final.

TrOCR spécialisé par LoRA

Nous partons de trocr-base-handwritten — un encodeur visuel ViT et un décodeur de texte. Il est déjà pré-entraîné sur de l'écriture manuscrite : son encodeur sait lire des formes, ce qui nous évite de tout réapprendre.

POURQUOI LORA ET PAS UN FINE-TUNING COMPLET ?

On gèle les 336 M de paramètres et on n'entraîne que de petites matrices de bas rang dans l'attention (encodeur et décodeur). Bénéfices : mémoire et temps réduits sur une seule A100, moins de surapprentissage, et un adaptateur de quelques Mo facile à versionner.

0,63 %

paramètres entraînés — 2 113 536 / 336 035 328

~50 min

entraînement (A100, 3 epochs, 9 228 steps)

RÉGLAGES

LoRA $r=16$, $\alpha=32$, dropout 0,05 · bf16 · lr $1e-4$ · batch 16 · seed 42.

Courbe de validation : CER 32,7 % (800 steps) → **16,6 %** en fin d'entraînement, reproductible au seed.

RÉSULTATS

Le fine-tuning fait toute la différence

76,7 % CER — TrOCR sans fine-tuning (baseline)	13,46 % CER — après fine-tuning LoRA (test scellé)	×5,7 réduction de l'erreur
--	--	--

Indicateur (test scellé, n=500)	Valeur	Seuil	Statut
CER — Character Error Rate	13,46 % · IC 95 % bootstrap [12,70 ; 14,28]	< 15 %	atteint
WER — Word Error Rate	43,80 %	< 25 %	à améliorer
Lignes « needs_review » (seuil calibré 0,70)	18,7 %	< 20 %	atteint

IC bootstrap sur 1000 ré-échantillonnages : l'intervalle est étroit, l'écart au seuil n'est pas un effet de hasard. Le WER élevé est cohérent avec le médiéval (une lettre fausse invalide le mot) — c'est notre axe d'amélioration, pas un échec.

Ce que le modèle produit, vraiment

AVANT FINE-TUNING — LE MODÈLE HALLUCINE DE L'ANGLAIS MODERNE

Réf. : Monseigneur sauuez uostre uie
TrOCR brut : by , appearances (fanning before the

APRÈS FINE-TUNING — TRANSCRIPTIONS FIDÈLES (EXEMPLES DU TEST)

corps les dyables en mon nom et – identique à la référence

Préd. : Denande a cēulz a que ie ay parle
Réf. : Demande a ceulz a qui Ie ay parle

Préd. : cieratur qui ciouca 7 sera baptiziez
Réf. : creature qui croira 7 sera baptiziez

Le modèle restitue le vieux français, ponctuation et abréviations comprises ; les erreurs résiduelles portent sur des lettres isolées proches visuellement (c/e, n/u).

Un data contract qui sait dire où il doute

SORTIE STRUCTURÉE & VALIDÉE (JSONSCHEMA)

Chaque ligne porte : texte, **polygone**, confiance globale **et par caractère**, **candidats alternatifs**, drapeau needs_review, métadonnées. Pensé pour la correction NLP guidée par la confiance.

```
{
  "id": "line_00042",
  "texte": "...",
  "confiance": 0.91,
  "confiance_char": [0.99, 0.62, ...],
  "candidats_char": [["a","e"], ...],
  "needs_review": false,
  "polygone": [[x,y], ...]
}
```

CALIBRATION DE LA CONFIANCE

La confiance par ligne est **fortement corrélée à l'erreur** : corrélation de $-0,775$. En fixant le seuil à 0,70 :

18,7 %

de lignes signalées à relire

35,5 % vs 13,4 %

CER des lignes signalées vs non signalées

Concrètement : relire 18,7 % des lignes attrape l'essentiel des erreurs. Le seuil est calibré, pas arbitraire.

Une page entière, et un test de généralisation

Nous avons fait tourner toute la chaîne sur une **page brute** (segmentation → transcription → PAGE XML), puis testé le modèle sur un manuscrit **jamais vu** : le Codex Manesse (allemand, vers 1300).

Entraîné **uniquement en français**, le modèle lit tout de même « ... der ...ogelweide » sur de la gothique allemande (réf. « von der Vogelweide »).

L'encodeur visuel généralise les formes de lettres au-delà de la langue ; les erreurs (von → no) viennent du modèle de langue français du décodeur. C'est la preuve concrète de la séparation perception visuelle / langue.

LA SEGMENTATION PILOTE LE CER (MÊMES DONNÉES, MÊME MODÈLE)

13,5 %

lignes bien segmentées (test scellé)

21,2 %

manuscrit dense, bien segmenté

71 %

page découpée par projection grossière

Conclusion d'ingénierie : le maillon faible n'est pas le HTR mais la segmentation — d'où le passage prévu à Kraken BLLA.

Difficultés rencontrées — et comment on les a réglées

Difficulté	Cause	Solution
Environnement Colab cassé à l'import	versions par défaut trop récentes	pile figée (transformers 4.46.3 / datasets 3.1.0)
Échec de sauvegarde du modèle	config PEFT sans vocab_size	save_embedding_layers=False
Runtime recyclé, modèle perdu	environnement non persistant	sauvegarde systématique sur Google Drive
Sur-/sous-segmentation des lignes	projection sur fonds denses	calibration + passage planifié à Kraken BLLA

LIMITES ASSUMÉES

WER encore élevé (43,8 %) ; biais du corpus (français, 13^e–15^e, Textualis) ; évaluation test sur un échantillon de 500 lignes ; Volet 2 non encore exécuté.

Où nous en sommes

Volet 1 — complet & validé

Pipeline de bout en bout, modèle entraîné/sauvegardé/évalué (CER 13,46 % < 15 %), data contract, calibration, tests pytest, reproductibilité (seed + SHA-256).

Volet 2 — fondations posées

L'interface (confiance et candidats par caractère) est déjà produite. Le démarrage est séquentiel par conception : le Volet 2 commence quand le Volet 1 livre — c'est le cas.

En une phrase : le Volet 1 livre un texte fidèle, localisé et calibré — exactement la matière première dont le Volet 2 a besoin pour passer du pixel au sens.

PLAN DES 2 SEMAINES

CV : Kraken BLLA + mesure IoU · run r=32 avec augmentation (test de McNemar) · publication du modèle sur HuggingFace.

NLP : normalisation (règles puis correction MLM guidée par confiance) · NER CamemBERT médiéval (schéma BIO) · POS (stanza frm) · graphe + export TEI-XML.